

Análisis y evolución de las empresas del S&P 500

Memoria del proyecto de Shell y Entornos Linux

Yassin Pellicer Lamla

September 11, 2026

Contents

1	Objetivo	2
2	Elección del dataset	2
2.1	Formato y estructura	2
2.2	Datos relevantes y preprocesamiento	3
3	Automatización mediante cron	3
4	Scripts de procesamiento	4
4.1	script_delete.sh	4
4.2	script_download.sh	4
5	Extracción y análisis de datos	4
6	Formato de los informes generados	4
7	Registro (log)	5
8	Estructura de ficheros del proyecto	5
9	Entrega del proyecto	5
A	Uso de IA en funciones de ayuda y formateo	5

1 Objetivo

El proyecto automatiza la descarga, depuración, análisis y presentación de información financiera de las compañías del índice S&P 500. Para cada ejecución diaria se conserva una instantánea del conjunto de datos y se generan informes de texto y HTML.

Los informes permiten consultar el ranking de capitalización bursátil, la agrupación por sectores y su ránking, las empresas que más próximas están a su máximo de 52 semanas y la evolución histórica de precio y capitalización.

2 Elección del dataset

El dataset utilizado en este proyecto consiste en un archivo .csv de 500 entradas correspondientes a los datos de cada una de las 500 empresas más rentables de la bolsa estadounidense. En este caso se utiliza un único dataset en formato CSV publicado por el repositorio abierto *S&P 500 Companies Financials* de la organización **datasets** en GitHub. Se descarga desde:

<https://raw.githubusercontent.com/datasets/s-and-p-500-companies-financials/main/data/constituents-financials.csv>

El repositorio público del dataset es:

<https://github.com/datasets/s-and-p-500-companies-financials>

La fuente es pública y accesible por descarga mediante el comando **wget**. El proyecto no presupone que el archivo sea una fuente de datos en tiempo real, ya que se actualiza una vez al día: simplemente satisface el requisito de actualización mediante una descarga programada diariamente, que guarda una instantánea con fecha propia.

2.1 Formato y estructura

El formato es CSV con una fila de cabecera y una fila por compañía. El script de descarga lo almacena como **datasets/constituents-financials_AAAAMMDD.csv**. Los campos son los siguientes:

Campo	Descripción
Symbol	Símbolo bursátil de la compañía.
Name	Nombre de la compañía.
Sector	Sector o industria asignada.
Price	Precio de la acción.
Price/Earnings	Relación precio-beneficio.
Dividend Yield	Rentabilidad por dividendo.
Earnings/Share	Beneficio por acción.
52 Week Low	Precio mínimo durante las últimas 52 semanas.
52 Week High	Precio máximo durante las últimas 52 semanas.

Campo	Descripción
Market Cap	Capitalización bursátil.
EBITDA	Beneficio antes de intereses, impuestos, depreciaciones y amortizaciones.
Price/Sales	Relación entre el precio y las ventas.
Price/Book	Relación entre el precio de mercado y el valor contable.
SEC Filings	URL de documentación presentada ante la SEC.

2.2 Datos relevantes y preprocesamiento

No todos estos datos son relevantes para el estudio. En el proyecto sólo se consideran los campos `Symbol`, `Name`, `Sector`, `Price`, `52 Week High` y `Market Cap`. El preprocesador invocado en el servicio de descarga automático se deshace de cualquier entrada que no tenga, como mínimo, estas columnas. Sin embargo, las columnas no significativas se conservan de todas maneras para permitir la ampliación y creación de métricas más complejas en un futuro.

3 Automatización mediante cron

El archivo `cron/crontab.txt` define una ejecución diaria a las 12:00:

```
0 12 * * * /ruta/al/proyecto/cron/script_cron.sh
```

El script `cron/script_cron.sh` ejecuta las etapas de limpieza, descarga, saneamiento y creación de informes. El procesamiento está separado en scripts Bash con responsabilidades concretas para cada uno:

- `script_delete.sh`: elimina snapshots CSV con más de 30 días.
- `script_download.sh`: descarga el CSV y reintenta la operación hasta diez veces ante un fallo de red.
- `script_sanitize.sh`: valida los campos requeridos y normaliza el CSV.
- `script_analisis_csv_txt.sh`: genera los informes de texto.
- `script_analisis_csv_html.sh`: genera el informe HTML a partir de las plantillas localizadas en `scripts/html/`.

Los scripts de análisis aceptan opcionalmente una fecha `AAAAMMDD`; si se omite, emplean la fecha actual. Esto permite regenerar un informe histórico sin volver a descargar el dataset.

4 Scripts de procesamiento

`cron/script_cron.sh` inicia el proceso automatizado por el servicio `cron` y ejecuta los 3 siguientes scripts de procesamiento

- `script_delete.sh`
- `script_download.sh`
- `script_sanitise.sh`

4.1 `script_delete.sh`

Este script borra por defecto los datasets con una antigüedad mayor de 30 días. Concretamente, extrae la fecha del nombre de los archivos y, mediante un bucle, comprueba si el archivo consultado tiene una antigüedad superior a 30 días respecto a la fecha actual. En ese caso, elimina el archivo.

4.2 `script_download.sh`

Este script descarga el `.csv` del remoto y le da un nombre especial que le añade la coletilla `_<date>` al final, de manera que el `.csv` descargado el 11/09/2026 se llamaría `constituents-financials_20260911.csv`.

5 Extracción y análisis de datos

La extracción se realiza con `curl` sobre la URL pública indicada. El análisis usa herramientas estándar de Unix, principalmente `awk`, `sort`, `tail`, `sed` y `wc`. Las operaciones principales son:

1. ordenar las empresas por **Market Cap** para el ranking principal;
2. sumar la capitalización por **Sector** y ordenar los sectores de forma descendente;
3. calcular la distancia porcentual entre el precio actual y el máximo de 52 semanas;
4. recorrer los snapshots disponibles hasta la fecha solicitada para mostrar la evolución de precio y capitalización por empresa.

El informe de evolución no incorpora datasets posteriores a la fecha de su propia instantánea, por lo que una ejecución histórica se mantiene coherente con el periodo analizado.

6 Formato de los informes generados

Para cada fecha se crea el directorio `analysis/AAAAMMDD/`. Los informes de texto son archivos `.txt` con tablas monoespaciadas. El informe HTML se genera en `analysis/AAAAMMDD/report/report_AAAAMMDD.html`, junto con su hoja de estilos y JavaScript.

El HTML incluye el ranking por capitalización, las tablas por sector, los mayores ganadores y la evolución. Las tablas incluyen numeración donde corresponde y un total de entradas procesadas, situado fuera del contenedor desplazable de cada bloque. El CSS y JavaScript se separan de la plantilla HTML para facilitar su mantenimiento.

7 Registro (log)

El archivo `log.txt` conserva un registro cronológico de todas las ejecuciones. Cada línea incluye fecha y hora con milisegundos, además del estado `[ok]` o `[ko]`. Se registran el inicio y el final de cada etapa, los archivos de entrada y salida, los reintentos de descarga y los registros descartados durante el saneamiento. Este registro permite auditar la automatización y diagnosticar errores.

8 Estructura de ficheros del proyecto

```
project/
|-- analysis/      informes generados, agrupados por fecha
|-- cron/          crontab y script orquestador diario
|-- datasets/      snapshots CSV descargados
|-- scripts/       descarga, limpieza, saneamiento y análisis
|   '-- html/      plantilla, estilos y JavaScript del informe web
'-- log.txt        registro de ejecuciones
project_doc/
'-- proyecto_shell_Yassin_Pellicer.tex
```

9 Entrega del proyecto

La entrega incluye los scripts ejecutables, el archivo de `cron`, las plantillas HTML/CSS/JavaScript, los datasets de ejemplo, los informes generados y esta memoria en formato $\text{\LaTeX}$. Para ejecutar el flujo completo se configura la entrada de `crontab` con la ruta absoluta del script orquestador o se ejecuta manualmente `cron/script_cron.sh`.

A Uso de IA en funciones de ayuda y formateo

Se utilizó asistencia de IA como apoyo al desarrollo, centrada en tareas de bajo riesgo y revisables: mejora del formato del informe HTML, definición de estilos CSS, incorporación de numeración y totales en tablas, y redacción inicial de esta memoria. La IA no sustituye la validación del proyecto: las decisiones sobre el dataset, la automatización, los comandos ejecutados y la verificación de los resultados se revisaron sobre los archivos y scripts del repositorio. No se empleó para inventar datos financieros ni para modificar la fuente de datos descargada.