

Shell en entornos Linux

Proyecto de asignatura



ANDRÉS TERRASA
DSIC – ETSINF – UPV
4-5/9/2026

MÁSTER F.P. EN IA & BIG DATA ANALYTICS
CURSO 2026-2027

Objetivo



- Diseñar un sistema **automatizado** que, periódicamente,
 - Descargue,
 - Analice, y
 - Genere **informes**
- a partir de un ***dataset* público** en Internet
- y documentarlo mediante una **memoria**

Resumen de requisitos



1. Elección del *dataset*
2. Automatización mediante cron
3. Script de procesamiento
4. Extracción de datos
5. Formato de los informes generados
6. Registro (log)
7. Estructura de ficheros del proyecto
8. Entrega del proyecto

1. *Dataset*



- La elección del *dataset* (uno o varios) es propia de cada proyecto
- Puede estar en formato CSV o JSON
- Debe proceder de una fuente oficial o reconocida de **datos abiertos** (acceso público)
- Debe recibir actualizaciones en **tiempo real** o al menos con frecuencia **diaria**

En la **memoria** se debe documentar el origen de los datos elegidos (URL y *datasets*), la información que contiene (estructura, formato de los campos) y cualquier otro aspecto relevante

1. *Dataset*



- Ejemplos de posibles *datasets*:
 - Datos meteorológicos en tiempo real:
 - ✧ <https://datos.gob.es/es/catalogo/101280796-datos-meteorologicos-datos-en-tiempo-real-acumulado1>
 - Tránsito en tiempo real:
 - ✧ <https://opendata.vlci.valencia.es/dataset/estat-transit-temps-real-estado-trafico-tiempo-real>
 - Estaciones de bicicletas JDecaux:
 - ✧ <https://public.opendatasoft.com/explore/dataset/jcdecaux-bike-stations-data-rt/information/?flg=en&location=3,49.59463,65.45542&basemap=jawg.light>

2. Automatización mediante cron



- El proceso debe realizarse al menos con periodicidad **diaria** (si es distinta, debe justificarse)
- Debe utilizarse **cron** para programar su ejecución periódica
- Debe registrarse la ejecución del script en un fichero de **log** con marcas de tiempo (descrito más adelante)

En la **memoria** se debe documentar y justificar la planificación elegida, incluyendo el contenido literal del fichero crontab

3. Script de procesamiento



- Para cada *dataset* el script debe realizar, como **mínimo**:
 - **Descarga** local (mediante `wget` o `curl`) en un fichero que debe renombrarse incluyendo marca de tiempo
 - ✦ El script deberá controlar **errores básicos** como: errores de descarga, fichero vacío, estructura errónea, etc. y registrarlos en el fichero de **log**
 - ✦ Se valorará la detección de cualquier otro tipo de error adicional
 - **Procesamiento** mediante `awk` (CSV) o `jq` (JSON)
 - **Limpieza** de datos (si puede haber anomalías en ellos)
 - Extracción de **datos procesados** (a continuación)
 - Generación de **informes** (a continuación)
- Además, se deben eliminar *datasets* descargados con más de N días de antigüedad (por ejemplo, N=7)

4. Extracción de datos procesados



- Para cada *dataset*, el script debe extraer como **mínimo** los siguientes datos:
 - Un **conteo** de los registros que contiene
 - Al menos una **métrica agregada** (p.ej., el mínimo, máximo o promedio) de algún campo numérico (en el que tenga sentido)
 - Al menos un **filtrado o selección** de datos (por año, por categoría, etc.) que demuestre la capacidad de extraer información específica que pueda resultar de interés

En la **memoria** se deberá justificar la decisión de qué datos se agregan o filtran. Se valorará la coherencia y utilidad de los datos extraídos respecto a los objetivos del proyecto

5. Generación de informes



- Con los datos extraídos en el punto anterior, el script debe producir **dos informes**:
 1. Informe en **texto plano** (con extensión .txt)
 2. Informe en **formato HTML** (con extensión .html), con una estructura básica: título, fecha, resultados (datos extraídos)
- Los informes en texto y HTML:
 - Contendrán básicamente la misma información, pero el HTML puede incorporar una presentación más vistosa
 - Sus ficheros deben incluir una marca temporal que coincidirá con sus correspondientes *datasets* descargados

5. Generación de informes



- De manera voluntaria, el script puede generar tablas u otros elementos de información adicionales en los informes que permitan extraer información útil del *dataset* o presentarla de manera más clara/eficaz

En la **memoria** se deberá explicar la estructura y la información que se obtiene en ambos informes. Se valorará que la presentación elegida sea coherente con los objetivos del proyecto

6. Registro (log)



- El proyecto debe incluir al menos un fichero de **log** que incluya, con marcas de tiempo:
 - las **tareas** desarrolladas por el script en cada ejecución: inicio, descarga, procesamiento, informes, etc., y finalización
 - Cualquier **error** que se produzca durante dichas tareas
- El log debe ser **acumulativo**, y no debe eliminar las entradas de ejecuciones anteriores
- De manera voluntaria, se puede considerar la generación adicional de *logs* más específicos

7. Estructura de ficheros del proyecto



- El proyecto debe mantener una **estructura** similar a esta:

```
nombre_del_proyecto_shell/  
├── datasets/  
│   ├── datos_20250301.csv (o .json)  
│   └── datos_20250302.csv (o .json)  
├── informes/  
│   ├── informe_20250301.txt  
│   ├── informe_20250301.html  
│   ├── informe_20250302.txt  
│   └── informe_20250302.html  
├── planificacion/  
│   └── crontab.txt  
├── script_analisis_csv.sh    (si se elige CSV)  
├── script_analisis_json.sh  (si se elige JSON)  
└── log.txt
```

8. Entrega del proyecto



- La entrega del proyecto incluirá **dos ficheros**:
 - Un **zip** que incluya la estructura de directorios y ficheros explicada en el punto anterior
 - ✦ Si los ficheros de datos descargados son muy grandes, deben eliminarse antes de generar el zip
 - La **memoria** del proyecto en **pdf**, que debe incluir una descripción (libre) del mismo. En esta memoria se valorará:
 - ✦ La **estructura** del documento: índice, introducción, secciones para cada apartado, conclusiones (incluyendo el uso de la IA)
 - ✦ La elección de los **contenidos** (destacando las decisiones adoptadas en el proyecto)
 - ✦ La **redacción**: corrección, claridad y concreción de las ideas
 - ✦ La **brevedad**: 10 páginas, como mucho

Rúbrica de evaluación del proyecto



Tarea	Aspectos valorables	Puntos
Fuente de datos	Selección de la fuente de datos (<i>dataset</i>) utilizada y descripción de esta en la memoria	0,5
Script: descarga	Descarga de <i>datasets</i> , nombrado de los ficheros, control de errores, calidad del script	2
Script: proceso	Limpieza de datos anómalos, extracción de datos (datos agregados, y filtrado de datos), uso de herramientas (awk, jq, sed, cut, sort, etc.), control de errores, calidad del script	2
Script: informes	Generación de informes en texto y html, nombrado de los ficheros, cantidad (y calidad) de información generada, control de errores, calidad del script	2
Automatización, logs y estructura	Programación de cron (crontab), generación de logs, estructura de ficheros, eliminación de ficheros antiguos	0,5
Memoria	Calidad de la memoria (estructura, redacción, claridad,...)	2
Mejoras	Mejoras incorporadas en el código y descritas en la memoria	1